ΠΑΝΕΠΙΣΤΗΜΙΟ ΘΕΣΣΑΛΙΑΣ
ΤΜΗΜΑ ΨΗΦΙΑΚΩΝ ΣΥΣΤΗΜΑΤΩΝ
ΠΡΟΓΡΑΜΜΑ ΜΕΤΑΠΤΥΧΙΑΚΩΝ ΣΠΟΥΔΩΝ

Αποθήκες Δεδομένων και Τεχνικές Ανάλυσης Δεδομένων

Εργασία Εξαμήνου

Εξόρυξη Γνώσης και Συναισθήματος από Δεδομένα Κειμένου

Χουλιάρας Δημήτριος – 013125027

---

1. Εισαγωγή & Περιγραφή Δεδομένων

Η παρούσα εργασία εστιάζει στην ανάλυση δεδομένων από το **Twitter** με στόχο την κατανόηση της παγκόσμιας συζήτησης γύρω από την πανδημία του **COVID-19**. Το σύνολο δεδομένων που χρησιμοποιήθηκε (covid19_tweets.csv) περιλαμβάνει αρχικά **179.108 tweets**, τα οποία καλύπτουν μια κρίσιμη χρονική περίοδο της πανδημίας. Μετά τη διαδικασία του καθαρισμού και του φιλτραρίσματος, αφαιρέθηκαν **9.613 tweets** τα οποία παρέμειναν κενά (χωρίς λέξεις-κλειδιά)που πιθανότατα ήταν είτε αναφορές σε άλλους χρήστες είτε URLs, αφήνοντας ένα τελικό δείγμα **169.495 tweets** προς ανάλυση.

Οι στήλες του αρχικού dataset είναι οι εξής:
user_name, user_location, user_description, user_created, user_followers, user_friends, user_favourites, user_verified, date, text, hashtags, source, is_retweet

Για την παρούσα εργασία, θα μας χρειαστεί μόνο η στήλη text.

Η ανάλυση κινείται σε δύο άξονες:

1. Την **Θεματική Μοντελοποίηση (Topic Modeling)** για τον εντοπισμό των κύριων θεμάτων (topic) της συζήτησης.
2. Την **Ανάλυση Συναισθήματος (Sentiment Analysis)** σε επίπεδο πολικότητας (θετικό/αρνητικό/ουδέτερο) και σε επίπεδο συγκεκριμένων ψυχολογικών καταστάσεων (π.χ. φόβος, εμπιστοσύνη κλπ.).

2. Προεπεξεργασία Δεδομένων (Preprocessing)

Πριν την εφαρμογή των αλγορίθμων, τα δεδομένα υποβλήθηκαν σε εκτεταμένη προεπεξεργασία (text mining pipeline) χρησιμοποιώντας τη βιβλιοθήκη tm της R. Τα βήματα που ακολουθήθηκαν ήταν:

- **Μετατροπή σε πεζά γράμματα:** Για την ομοιομορφία των λέξεων.
- **Αφαίρεση URLs και Ειδικών Χαρακτήρων:** Καθαρισμός συνδέσμων και Twitter-specific συμβόλων (π.χ. amp, …).
- **Αφαίρεση Σημείων Στίξης:** Εστίαση αποκλειστικά στο λεκτικό περιεχόμενο αγνοώντας σύμβολα.
- **Αφαίρεση Αριθμών:** Εστίαση αποκλειστικά στο λεκτικό περιεχόμενο αγνοώντας αριθμούς.
- **Αφαίρεση Stopwords:** Απομάκρυνση κοινών αγγλικών λέξεων χωρίς σημασιολογικό βάρος (π.χ. 'the', 'is', 'at').
- **Αφαίρεση Κενών:** Απομόνωση του καθαρά κειμενικού περιεχομένου και αφαίρεση "θορύβου" που θα μπορούσε να αλλοιώσει τα στατιστικά μοντέλα.
- **Stemming (Αναγωγή στη ρίζα):** Χρήση του αλγορίθμου Porter για την ενοποίηση διαφορετικών κλίσεων της ίδιας λέξης (π.χ. 'vaccination' και 'vaccines' ανάχθηκαν στη ρίζα 'vaccin').
- **Tokenization:** Η διαδικασία κατά την οποία το ενιαίο κείμενο κάθε tweet διασπάται σε μεμονωμένες μονάδες-λέξεις (tokens), οι οποίες αποτελούν τη βάση για τη δημιουργία του Πίνακα Εγγράφων-Όρων (Document-Term Matrix).
- **Sparsity Control:** Αφαίρεση σπάνιων όρων που εμφανίζονταν σε λιγότερο από το 1% των tweets, προκειμένου να βελτιωθεί η υπολογιστική απόδοση του μοντέλου LDA."

Tweet πριν:
"The vaccination process in India is going great! http://link.gov.in I am happy with that"

Tweet μετά:
"vaccin process india great happi"

Κρατήσαμε μόνο τις λέξεις εκείνες που είναι σημαντικές για να μειώσουμε τον θόρυβο και να διευκολύνουμε το μοντέλο στα επόμενα στάδια.

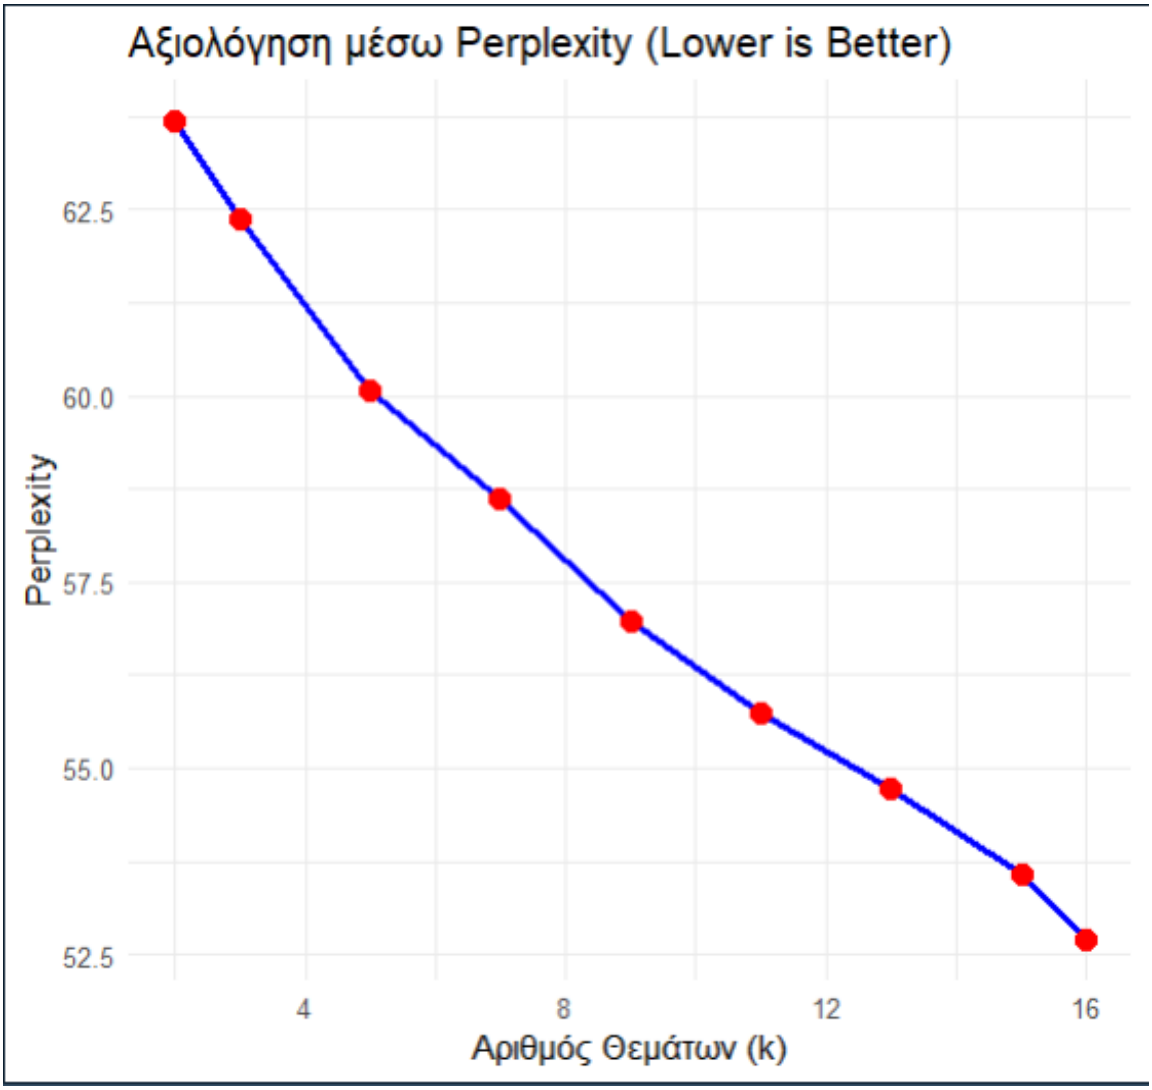
3. Θεματική Μοντελοποίηση (Topic Modeling - LDA)

Σε αυτή την ενότητα περιγράφεται η διαδικασία ομαδοποίησης των tweets σε θεματικές ενότητες με τη χρήση του αλγορίθμου **Latent Dirichlet Allocation (LDA)**.

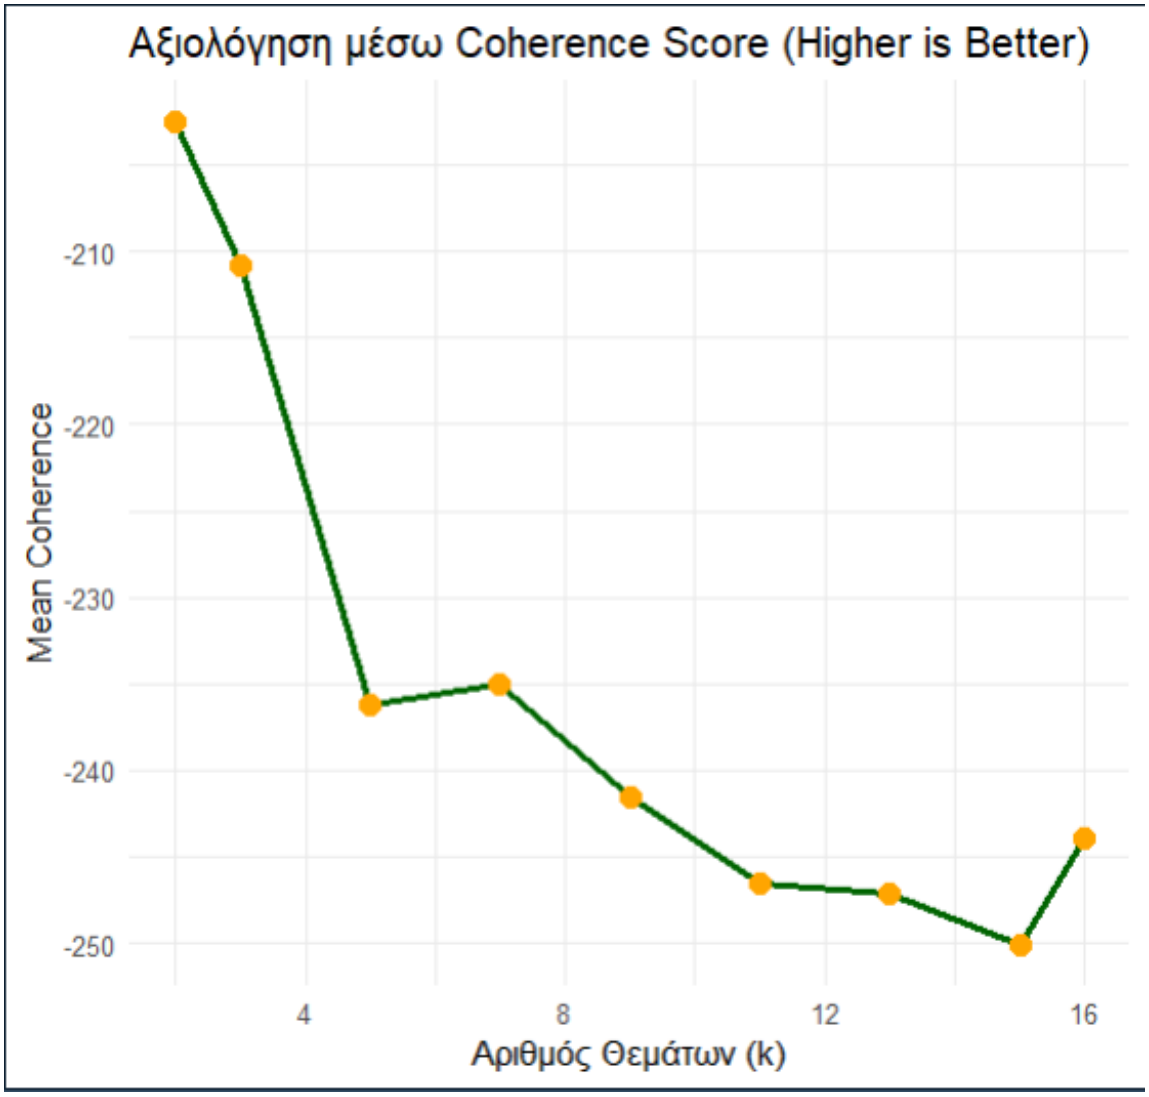
3.1 Επιλογή Αριθμού Θεμάτων (k)

Για τον προσδιορισμό του βέλτιστου αριθμού θεμάτων k, χρησιμοποιήθηκαν δύο στατιστικοί δείκτες:

- **Perplexity:** Μετρά πόσο καλά το μοντέλο προσαρμόζεται στα δεδομένα. Στόχος είναι η εύρεση του σημείου όπου η τιμή σταθεροποιείται (Elbow Method).
- **Topic Coherence:** Μετρά τη σημασιολογική συνοχή των λέξεων μέσα σε κάθε θέμα. Στόχος είναι η μέγιστη δυνατή τιμή.



Εικόνα 1 - Παρατηρούμε μια συνεχή πτώση καθώς αυξάνεται ο αριθμός των θεμάτων (k). Το Perplexity είναι ένας δείκτης που μας δείχνει πόσο καλά το μοντέλο 'ταιριάζει' στα δεδομένα. Θέλουμε η τιμή να είναι χαμηλή, αλλά εδώ δεν βλέπουμε ένα ξεκάθαρο 'γόνατο' (elbow point) που να υποδεικνύει τον ιδανικό αριθμό θεμάτων, οπότε θα βασιστούμε στο Topic Coherence για να επιλέξουμε.



Εικόνα 2 - Αυτός ο δείκτης μας δείχνει τη σημασιολογική συνοχή των θεμάτων, δηλαδή αν οι λέξεις που απαρτίζουν ένα θέμα έχουν κοινό νόημα. Θέλουμε η τιμή να είναι όσο το δυνατόν υψηλότερη. Όπως φαίνεται στο γράφημα, η υψηλότερη τιμή Coherence εμφανίζεται για k=4 θέματα, ενώ μια άλλη, μικρότερη, κορυφή εμφανίζεται για k=7. Σκοπός μας είναι να επιλέξουμε έναν αριθμό θεμάτων που να έχει καλή συνοχή, αλλά να μην είναι πολύ μικρός για να μην χάσουμε πληροφορίες, ούτε πολύ μεγάλος για να μην έχουμε επικαλύψεις.

Για τον προσδιορισμό του βέλτιστου αριθμού θεμάτων (k), πραγματοποιήθηκε δοκιμαστική εκτέλεση του μοντέλου για ένα εύρος τιμών από k=2 έως k=16. Βάσει των γραφημάτων αξιολόγησης, επιλέχθηκε η τιμή **k=5**, καθώς πρόσφερε την καλύτερη ισορροπία μεταξύ στατιστικής ακρίβειας και ερμηνευτικής ικανότητας.

3.2 Παρουσίαση και Ερμηνεία Θεμάτων

Μετά την εκτέλεση του μοντέλου LDA για k=5, τα 5 θέματα ερμηνεύτηκαν βάσει των 10 επικρατέστερων λέξεων (Top Terms) και ονομάστηκαν ως εξής:

Θέμα 1: Ατομική Προστασία & Μέτρα Πρόληψης (Prevention & Masks)

- **Λέξεις-κλειδιά:** mask, wear, safe, face, keep, hand.
- **Ερμηνεία:** Το θέμα αυτό επικεντρώνεται στις οδηγίες δημόσιας υγείας και την προσωπική ευθύνη. Τα tweets αφορούν τη χρήση μάσκας, την υγιεινή των χεριών και γενικότερα το πώς να παραμείνει κανείς ασφαλής στην καθημερινότητά του.

Θέμα 2: Πολιτική Επικαιρότητα & Κοινή Γνώμη (Politics & Public Opinion)

- **Λέξεις-κλειδιά:** trump, realdonaldtrump, peopl, american, will, say.
- **Ερμηνεία:** Εδώ κυριαρχεί η πολιτική διάσταση της πανδημίας, με έντονη αναφορά στον τότε Πρόεδρο των ΗΠΑ (Donald Trump). Το θέμα αντανακλά τις συζητήσεις γύρω από τις κυβερνητικές αποφάσεις και τις αντιδράσεις των πολιτών.

Θέμα 3: Επιστημονική Ενημέρωση & Εμβολιασμός (Science & Vaccines)

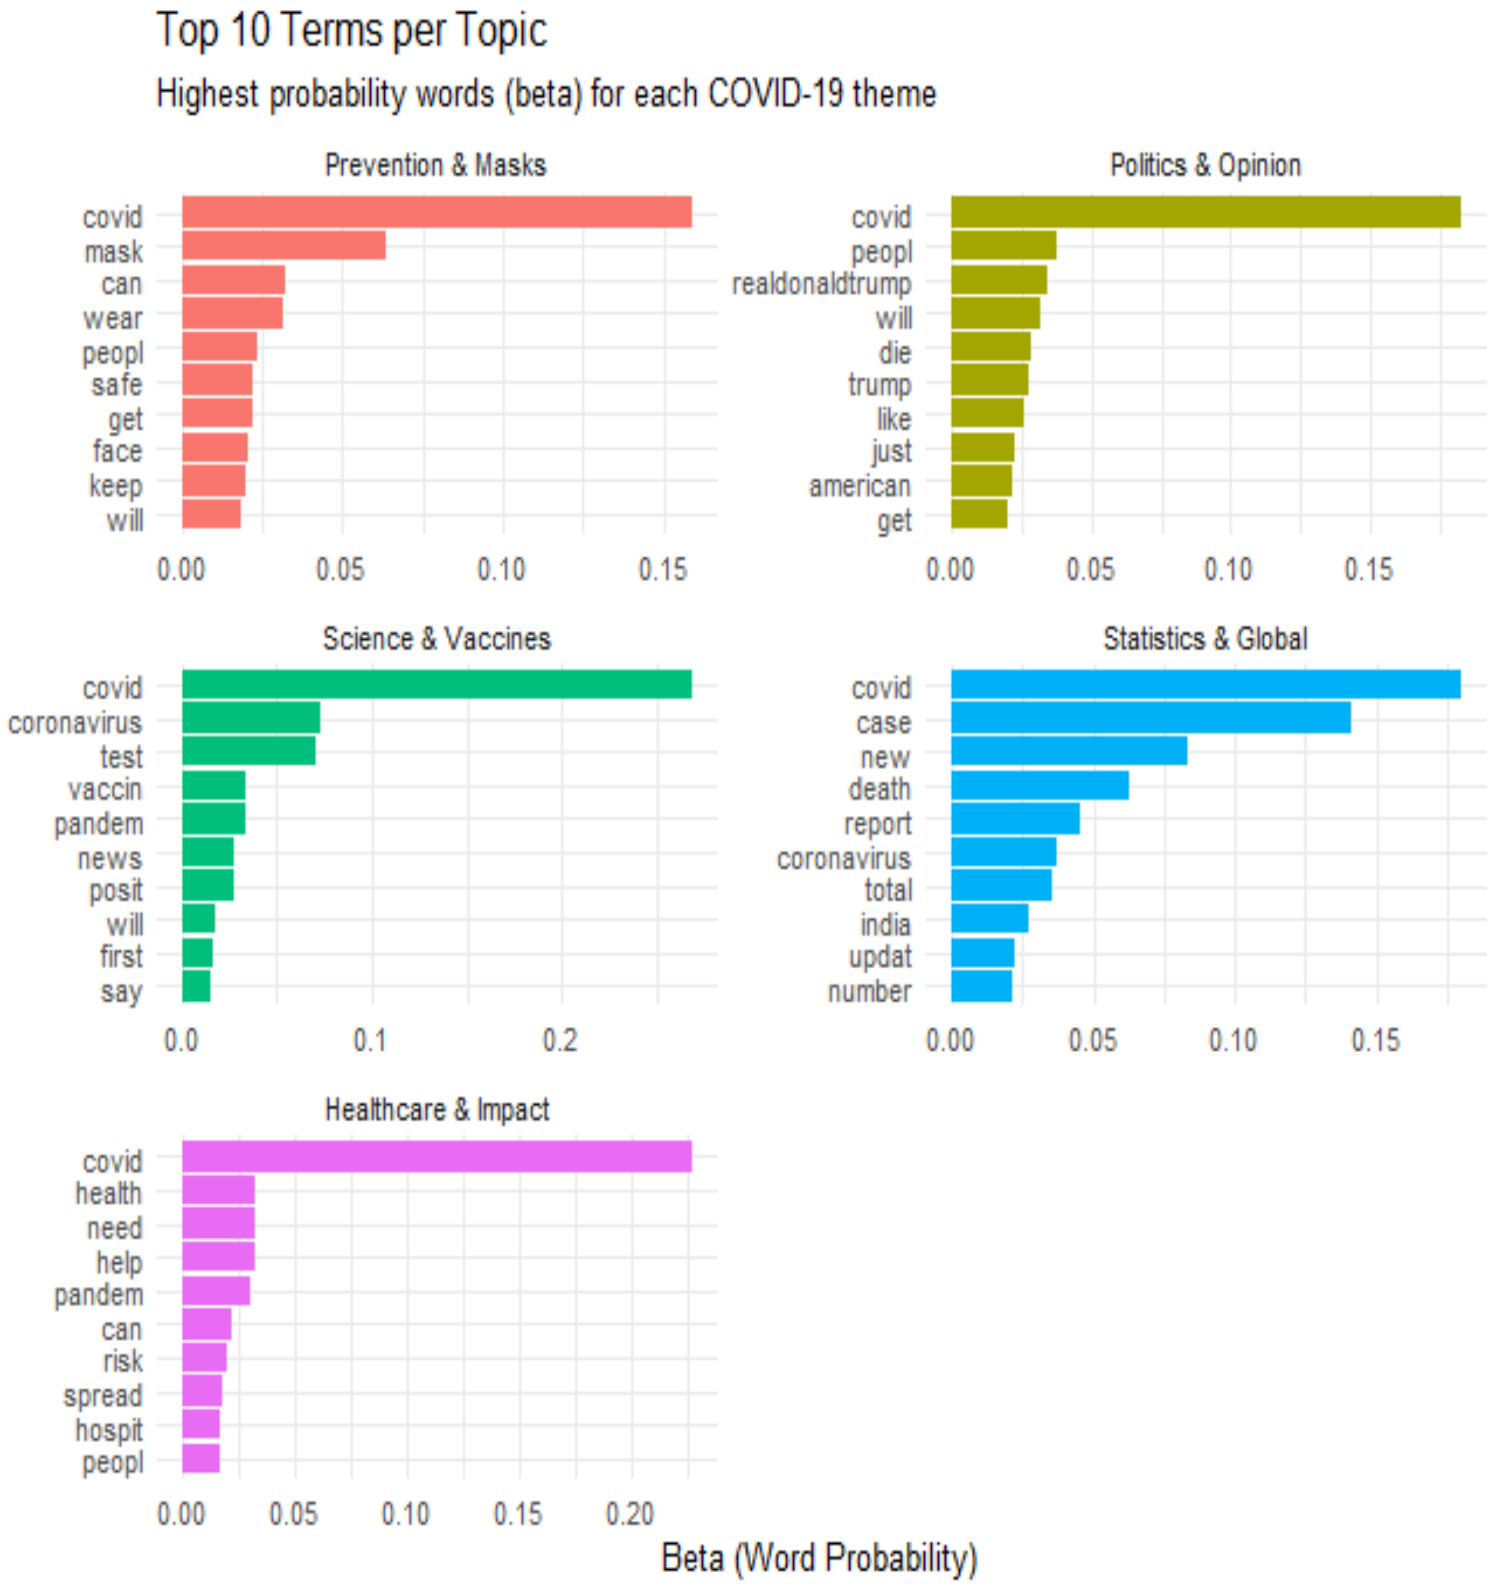
- **Λέξεις-κλειδιά:** test, vaccin, coronavirus, pandem, news, posit.
- **Ερμηνεία:** Αυτό το θέμα αφορά την ιατρική και ειδησεογραφική πλευρά. Περιλαμβάνει ενημερώσεις για την πρόοδο των εμβολίων, τα αποτελέσματα των τεστ (θετικά κρούσματα) και τις γενικές ειδήσεις γύρω από την εξέλιξη της πανδημίας.

Θέμα 4: Στατιστική Παρακολούθηση & Διεθνή Δεδομένα (Statistics & Global Cases)

- **Λέξεις-κλειδιά:** case, new, death, india, report, total, number.
- **Ερμηνεία:** Το θέμα αυτό είναι καθαρά πληροφοριακό και στατιστικό. Εστιάζει στην αναφορά των αριθμών (νέα κρούσματα, θάνατοι) σε παγκόσμιο επίπεδο, με ιδιαίτερη έμφαση στην Ινδία, η οποία εκείνη την περίοδο βρισκόταν στο επίκεντρο της κρίσης.

Θέμα 5: Σύστημα Υγείας & Κοινωνικός Αντίκτυπος (Healthcare & Social Impact)

- **Λέξεις-κλειδιά:** health, need, help, risk, spread, hospit.
- **Ερμηνεία:** Εδώ αναδεικνύεται η πίεση στα συστήματα υγείας (νοσοκομεία) και η ανάγκη για υποστήριξη. Τα tweets αφορούν τους κινδύνους διασποράς και τις εκκλήσεις για βοήθεια ή ενίσχυση των δομών υγείας.



*Εικόνα 3 - Στο γράφημα απεικονίζονται οι λέξεις με την υψηλότερη πιθανότητα εμφάνισης (**Beta Score**) για κάθε ένα από τα 5 θέματα που προέκυψαν από το μοντέλο LDA. Το Beta Score υποδηλώνει πόσο στενά συνδεδεμένη είναι μια λέξη με το συγκεκριμένο θέμα.*

4. Ανάλυση Συναισθήματος (Sentiment Analysis)

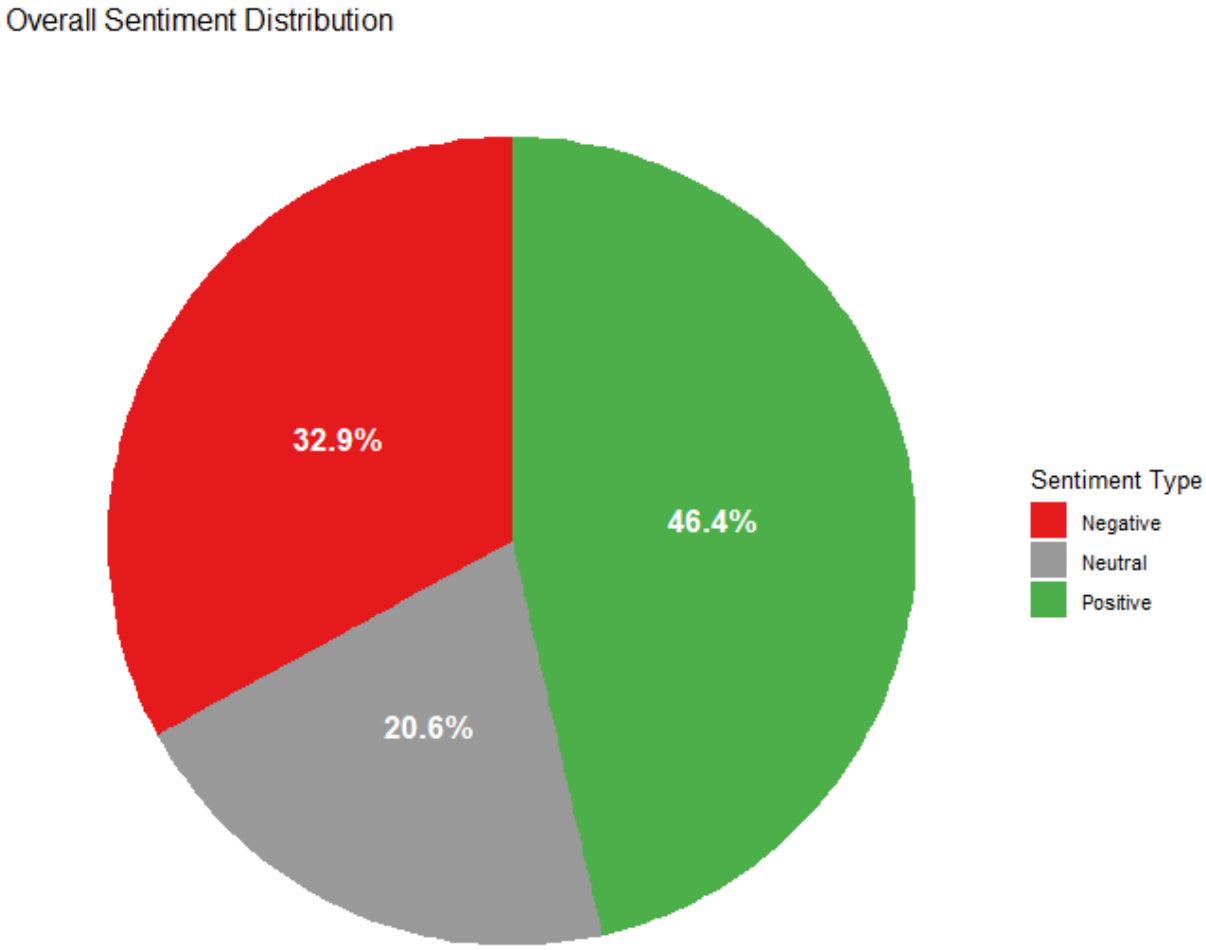
Η ανάλυση συναισθήματος πραγματοποιήθηκε σε δύο επίπεδα, χρησιμοποιώντας τη βιβλιοθήκη syuzhet, η οποία επιτρέπει την εξαγωγή συναισθηματικής φόρτισης μέσω προκαθορισμένων λεξικών.

4.1 Επίπεδο i: Πολικότητα (Polarity)

Για τον προσδιορισμό της γενικής στάσης των χρηστών (Θετική, Αρνητική ή Ουδέτερη), χρησιμοποιήθηκε η μέθοδος **Syuzhet**. Ο αλγόριθμος αποδίδει ένα δεκαδικό σκορ σε κάθε tweet:

- **Σκορ > 0:** Θετικό συναίσθημα.
- **Σκορ < 0:** Αρνητικό συναίσθημα.

Η "Ζώνη Ουδετερότητας": Προκειμένου να αποφευχθούν λανθασμένες ταξινομήσεις σε tweets με πολύ χαμηλή φόρτιση, ορίστηκε μια ζώνη ουδετερότητας μεταξύ **-0.15 και 0.15**. Tweets που εμπίπτουν σε αυτό το εύρος χαρακτηρίστηκαν ως **Neutral** (Ουδέτερα), εξασφαλίζοντας μεγαλύτερη ακρίβεια στα αποτελέσματα.



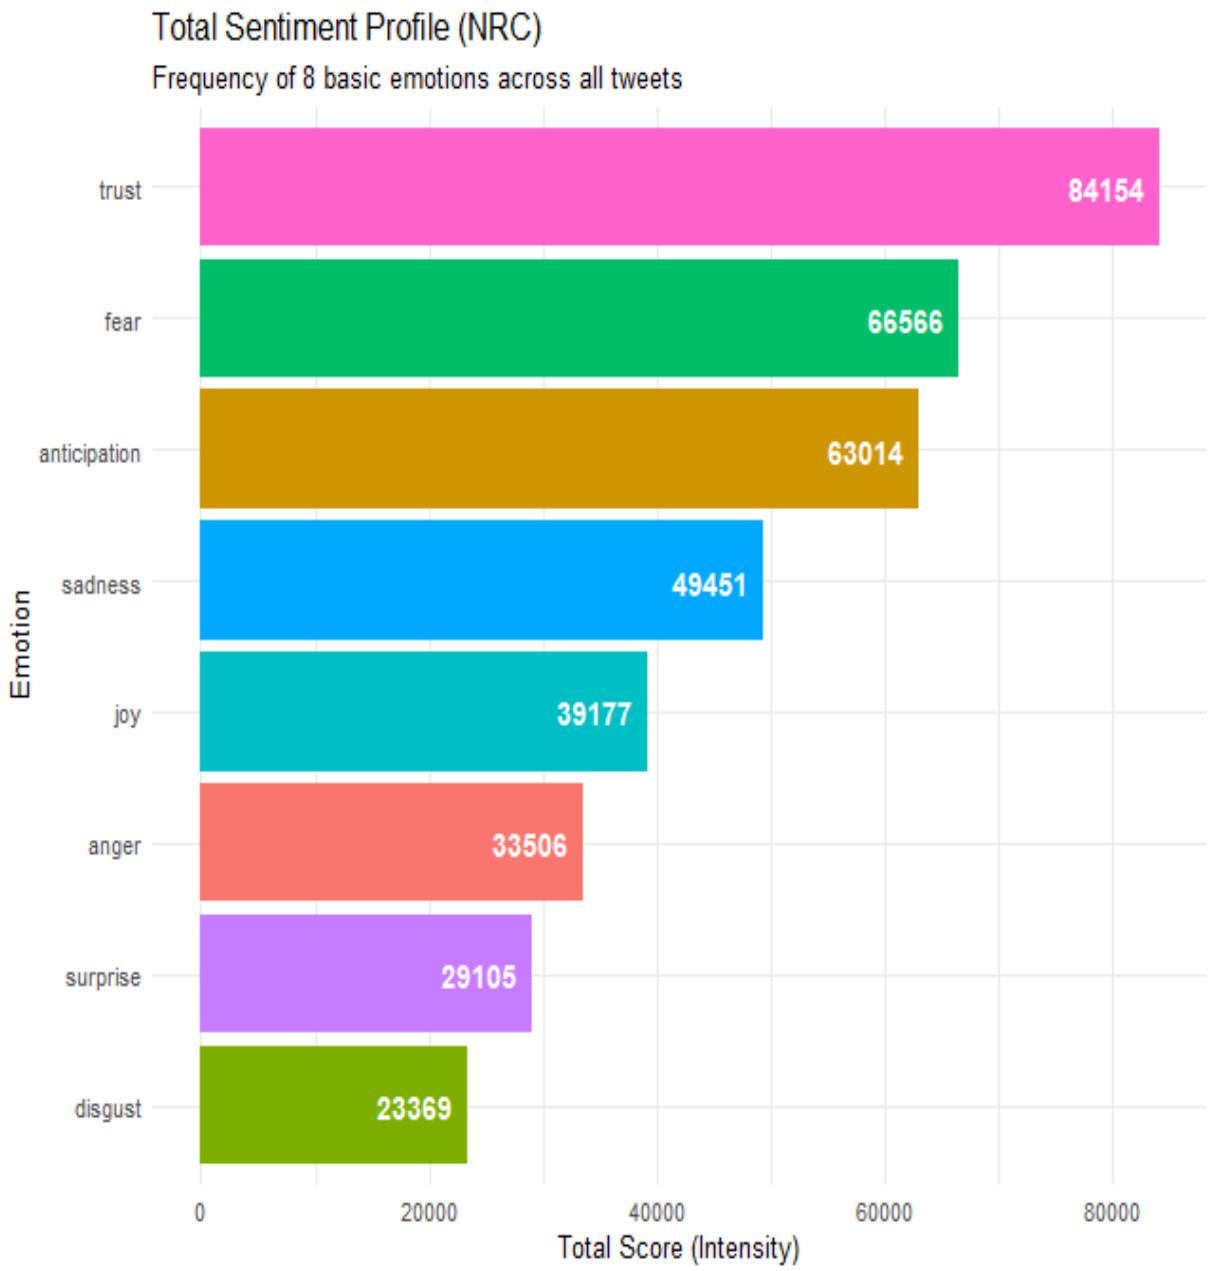
*Εικόνα 4 - Συνολική κατανομή πολικότητας του δείγματος. Παρατηρείται ότι το **46.4%** των tweets παρουσιάζει θετική χροιά, το **32.9%** αρνητική, ενώ ένα **20.6%** παραμένει ουδέτερο.*

4.2 Επίπεδο ii: Συναισθηματικό Προφίλ (NRC Emotions)

Πέρα από την απλή πολικότητα, χρησιμοποιήθηκε το λεξικό **NRC (National Research Council Canada)** για την ανίχνευση 8 βασικών συναισθημάτων:

- **Anger** (Θυμός), **Anticipation** (Προσμονή), **Disgust** (Αηδία), **Fear** (Φόβος), **Joy** (Χαρά), **Sadness** (Θλίψη), **Surprise** (Έκπληξη) και **Trust** (Εμπιστοσύνη).

Αυτή η προσέγγιση μας επιτρέπει να δούμε την "ψυχολογία" πίσω από τις ειδήσεις. Για παράδειγμα, ένα tweet μπορεί να είναι αρνητικό επειδή εκφράζει *φόβο* για την πανδημία, ή επειδή εκφράζει *θυμό* για τα μέτρα.

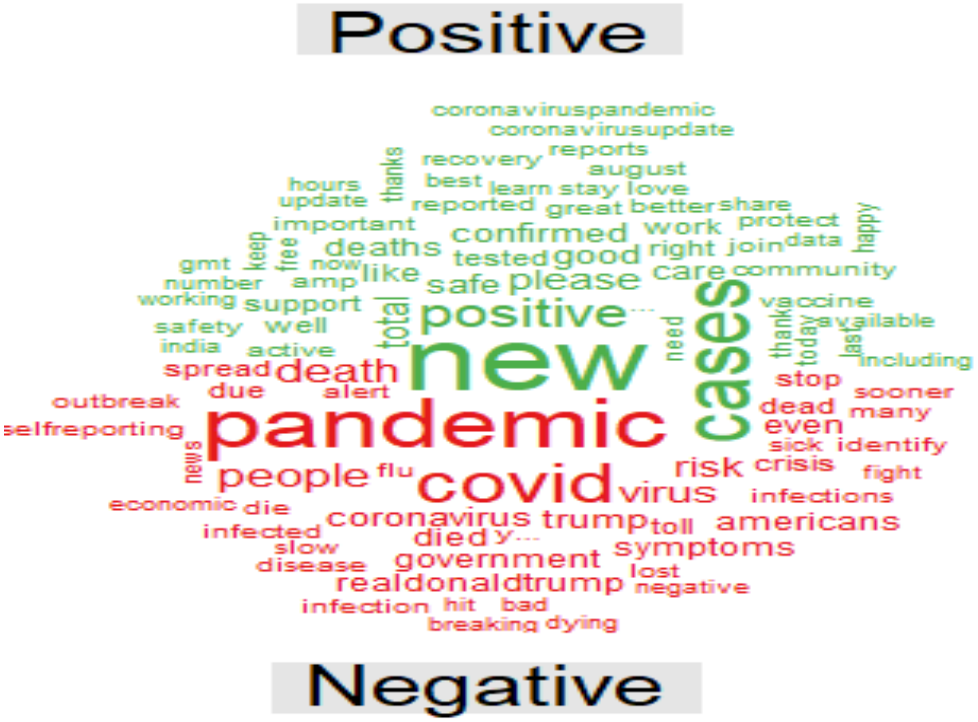


Εικόνα 5 - Συνολικό συναισθηματικό προφίλ του δείγματος βάσει του λεξικού NRC. Η υψηλή συχνότητα της κατηγορίας 'Trust' υποδηλώνει την εμπιστοσύνη στις επίσημες οδηγίες, ενώ η κατηγορία 'Fear' αντικατοπτρίζει την ανησυχία της κοινής γνώμης.

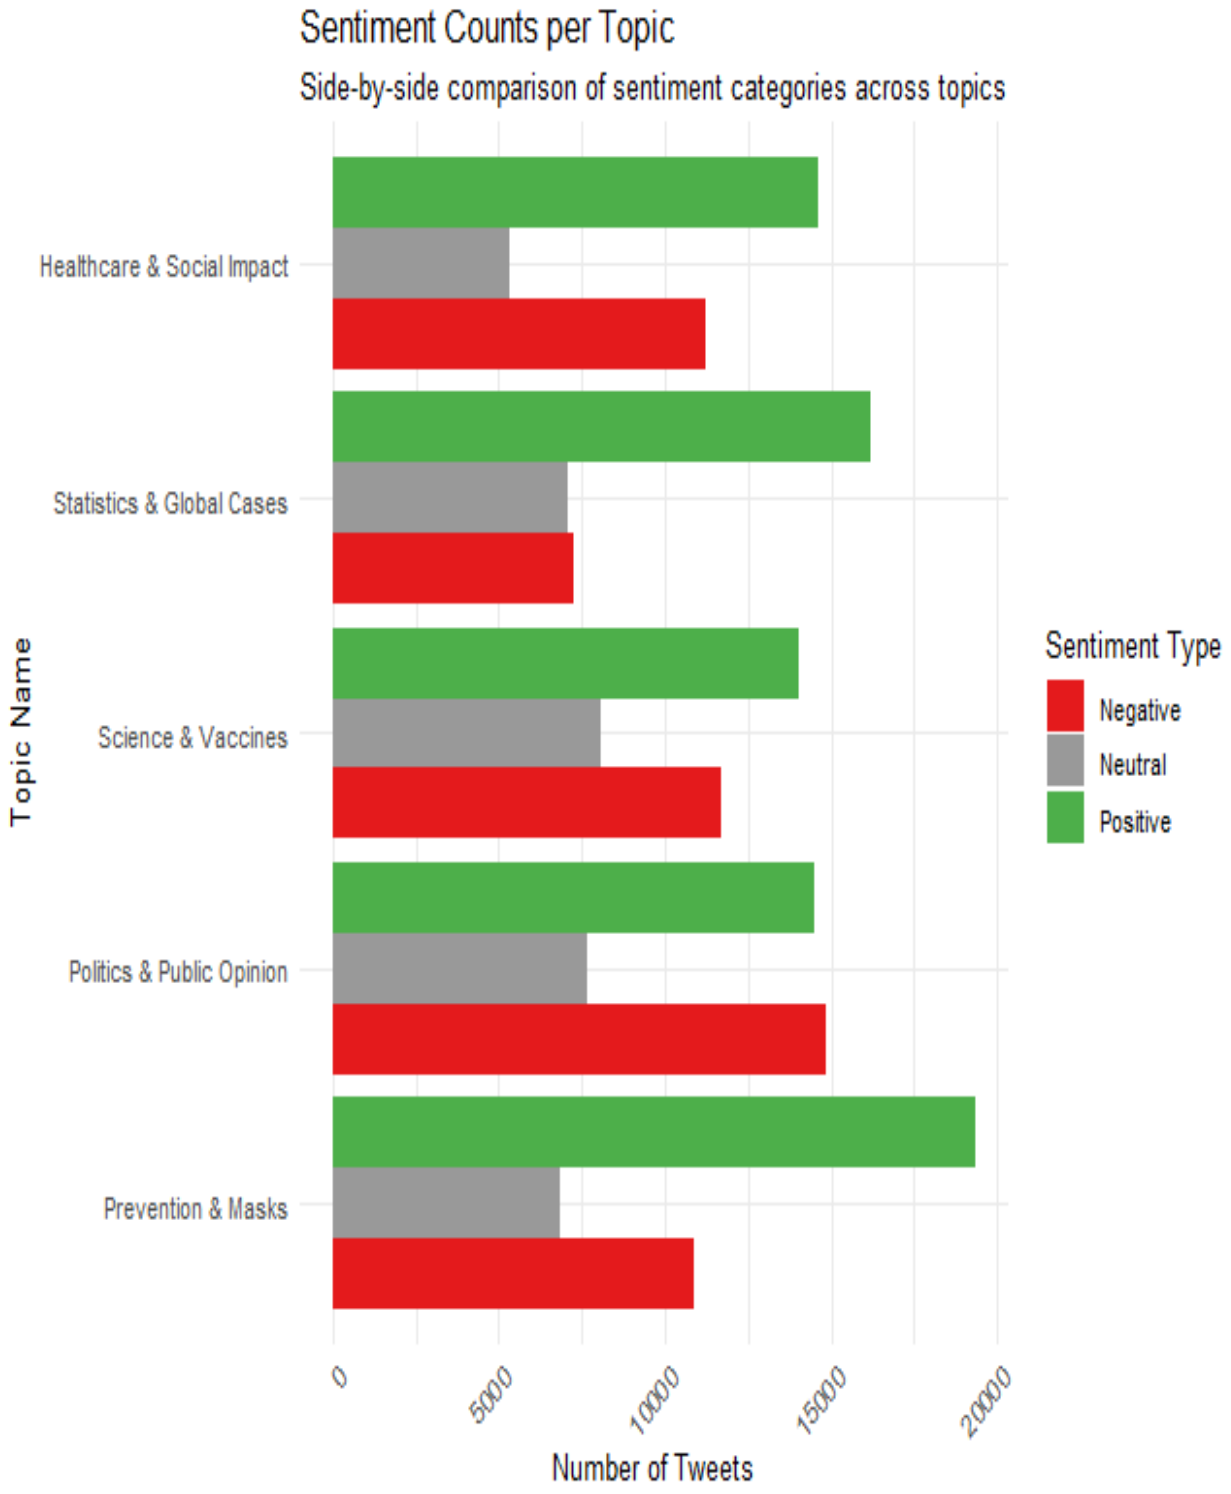
5. Σύνδεση Θεμάτων & Συναισθήματος (Matching)

Η συνδυαστική ανάλυση θεματικών ενοτήτων και συναισθήματος αποκάλυψε σημαντικές διαφοροποιήσεις στον τρόπο που οι χρήστες αντιδρούν σε διαφορετικές πτυχές της πανδημίας:

- **Healthcare & Social Impact:** Εδώ καταγράφεται μια σταθερή υποστήριξη προς το σύστημα υγείας αλλά με πολλές αρνητικές αναφορές για τον τρόπο λειτουργίας και απόδοσης των νοσοκομειακών μονάδων.
- **Statistics & Global Cases:** Παρά τη φύση του θέματος που αφορά θανάτους και κρούσματα (λέξεις 'death', 'cases'), η παρουσία πολλών ενημερωτικών tweets (news reports) κρατά το συναίσθημα σε μια ισορροπία μεταξύ αρνητικού και ουδέτερου και επικρατεί το θετικό συναίσθημα.
- **Science & Vaccines:** Το συγκεκριμένο θέμα παρουσιάζει μια ιδιαίτερη δυναμική, καθώς η θετική και η αρνητική πολικότητα βρίσκονται σε πολύ κοντινά επίπεδα.
- **Politics & Public Opinion:** Εδώ παρατηρείται η μεγαλύτερη συναισθηματική ένταση και πόλωση. Είναι το θέμα με το υψηλότερο ποσοστό αρνητικών αναφορών, γεγονός που εξηγείται από τις έντονες πολιτικές αντιπαραθέσεις
- **Prevention & Masks:** Το θέμα αυτό παρουσιάζει τον μεγαλύτερο όγκο tweets με σαφή κυριαρχία του θετικού συναισθήματος. Οι χρήστες φαίνεται να υιοθετούν μια προστατευτική στάση απέναντι στα μέτρα ατομικής ευθύνης.



Εικόνα 6 - Σύγκριση λεξιλογίου μεταξύ θετικών και αρνητικών tweets. Η οπτικοποίηση αναδεικνύει τις λέξεις-κλειδιά που διαμορφώνουν το συναισθηματικό κλίμα της περιόδου.



Εικόνα 7 - Πλήρης συσχέτιση θεματικών ενοτήτων και πολικότητας συναισθήματος. Παρατηρείται η υπεροχή της θετικής στάσης στα θέματα πρόληψης, ενώ η πολιτική συζήτηση παρουσιάζει τα υψηλότερα ποσοστά αρνητισμού.

6. Συμπεράσματα

Η ολοκλήρωση της ανάλυσης των 169.495 tweets επέτρεψε την εξαγωγή σημαντικών συμπερασμάτων σχετικά με τη δημόσια συζήτηση για την πανδημία του COVID-19:

- Θεματική Συνοχή: Η χρήση του μοντέλου LDA με k=5 θεματικές ενότητες αποκάλυψε ότι ο λόγος των χρηστών δομήθηκε γύρω από σαφείς πυλώνες, όπως η πρόληψη, η επιστημονική πρόοδος και η πολιτική αντιπαράθεση. Η στατιστική αξιολόγηση μέσω των δεικτών Perplexity και Coherence εξασφάλισε την εγκυρότητα της κατηγοριοποίησης.
- Συναισθηματική Τάση: Παρά τη σοβαρότητα της υγειονομικής κρίσης, η ανάλυση έδειξε μια κυριαρχία του θετικού συναισθήματος (46.4%), η οποία συνδέεται κυρίως με τα ατομικά μέτρα προστασίας των πολιτών και μετά με τον καθησυχασμό των χρηστών από ενημερωτικά reports.
- Πεδίο Αντιπαράθεσης: Η πολιτική διάσταση (Politics & Public Opinion) και η επιστημονική ενημέρωση (Science & Vaccines) αποτέλεσαν τα πιο "φορτισμένα" θέματα. Στις ενότητες αυτές παρατηρήθηκε η μεγαλύτερη συναισθηματική πόλωση, με τον φόβο (Fear) και τον σκεπτικισμό να εξισορροπούν την αρχική αισιοδοξία.
- Αξία της Μεθοδολογίας: Η παρούσα εργασία απέδειξε ότι ο συνδυασμός Topic Modeling και Sentiment Analysis αποτελεί ένα πανίσχυρο εργαλείο για την κατανόηση της κοινωνικής ψυχολογίας σε πραγματικό χρόνο. Η δυνατότητα επεξεργασίας χιλιάδων κειμένων αυτοματοποιημένα επιτρέπει στους φορείς λήψης αποφάσεων να εντοπίζουν έγκαιρα τις ανάγκες και τις ανησυχίες των πολιτών.

Δεδομένα (Dataset): https://www.kaggle.com/datasets/gpreda/covid19-tweets

Repository: https://github.com/Dimitris-Chouliaras/covid19-tweets-nlp-project

Εργαλεία: R, Rstudio